

Sesiunea 4: Construirea Agentului AI Autonom (Arhitectura RAG)

Capitolul 6: Agentul Conversațional și Arhitectura RAG (Chat cu Documentele Tale).....	1
1. Izolarea Fluxului: Crearea unui nou Trigger.....	1
2. Adăugarea "Creierului" (Nodul AI Agent).....	2
3. Echiparea Agentului (Model, Memorie și Unealta RAG).....	3
4. Traducătorul Agentului (Embeddings).....	5
5. Momentul Adevărului: Conversația cu Datele Tale!.....	6

Capitolul 6: Agentul Conversațional și Arhitectura RAG (Chat cu Documentele Tale)

 În acest ultim capitol, dăm o voce asistentului nostru. Avem fișierele descărcate și transformate în vectori în Pinecone. Acum vom construi o interfață de Chat în n8n, unde un Agent AI va citi întrebările noastre, va căuta răspunsul în Pinecone și ne va formula un răspuns uman și tehnic.


1. Izolarea Fluxului: Crearea unui nou Trigger

Până acum, fluxul nostru pornea de la un eveniment din Google Drive. Dar acum dorim ca acțiunea să pornească atunci când *noi* îi scriem un mesaj asistentului.

Pentru a păstra planșa curată și a nu descărca fișiere de fiecare dată când vorbim cu AI-ul, vom adăuga un punct de pornire complet separat pe același canvas (sau poți crea un Workflow nou, dacă preferi).

- Dă dublu-click oriunde pe un spațiu gol de pe planșa ta de lucru (canvas) pentru a adăuga un nod nou, departe de fluxul vechi.


- Caută în bara de căutare direct opțiunea **Chat** (prima din listă, cu iconița simplă de mesaj) și dă click pe ea.
- Se va deschide un sub-meniu. **Ignoră secțiunea Actions!** Du-te direct la secțiunea **Triggers** (marcată cu un mic fulger portocaliu) și deschide-o. Dă click pe opțiunea de acolo numită **On new Chat event**. Nodul care va apărea pe planșă este conceput pentru a deschide o fereastră de chat interactivă direct în interfața n8n.



2. Adăugarea "Creierului" (Nodul AI Agent)

Agentul este "managerul" operațiunii. El decide dacă poate să îți răspundă din memorie sau dacă are nevoie să folosească o unealtă (Tool) pentru a căuta în documente.

- Trage un fir din noul tău nod de Chat și caută nodul **AI Agent** (îl găsești în secțiunea *Advanced AI*).




- Odată adăugat, vei vedea că acest nod are mai multe porturi de conectare inferioare, fiecare având un rol specific pentru a construi "omulețul" nostru digital.

3. Echiparea Agentului (Model, Memorie și Unealta RAG)

Ca un agent să funcționeze corect, are nevoie de o personalitate, o memorie și o modalitate de a căuta în baza noastră de date. Le vom adăuga pe rând folosind porturile lui inferioare:

A. Modelul (Gura și Personalitatea)

- Apasă pe portul inferior stâng al nodului *AI Agent*, numit **Model**.
- Alege **OpenAI Chat Model**.
- Selectează aceleași credențiale (cheia API) pe care le-ai creat la capitolul anterior.
- La secțiunea Model, selectează gpt-4o-mini (este extrem de rapid, inteligent și costă fracțiuni de cent).



B. Memoria (Contextul conversației)

- Apasă pe portul inferior central al nodului *AI Agent*, numit **Memory**.
- Alege opțiunea **Simple Memory** (o găsești sub categoria *For beginners*).
- *De ce facem asta?* Fără memorie, dacă îl întrebi "Ce este o eroare 404?", el îți răspunde, dar dacă la următoarea întrebare spui "Și cum o rezolv?", el va uita complet la ce te-ai referit în prima propoziție! *Simple Memory* acționează ca un buffer, reținând istoricul discuției curente pe durata sesiunii, direct în RAM-ul n8n.

Schema **Table** **JSON** **Parameters** **Settings**

This node stores memory locally in the n8n instance. It is not compatible with Queue Mode or Multi-Main setups, as memory will not be shared across workers. For production use with scaling, consider using an external memory store such as Redis, Postgres, or another persistent memory node.

Session ID

Connected Chat Trigger Node

Session Key From Previous Node

fx `{{ $json.sessionId }}`

312f5d8bbbd144f9a05e475c1dbc46d3

Session is automatically scoped only to this memory node. To share a session between different memory nodes, switch "Session ID" to "Define below" and use the same key in each node.

Context Window Length

5

How many past interactions the model receives as context

C. Unealta de căutare (Pinecone Vector Store)

Aici se întâmplă magia prin care unim acest chat cu munca noastră din Capitolul 5. Platforma n8n ne permite să legăm baza noastră de date direct ca pe o "unealtă" pe care AI-ul o folosește singur.

- Apasă pe portul inferior drept al nodului *AI Agent*, numit **Tool** (sau pe semnul + de sub el).

- În meniul care apare, ignoră categoriile de sus și caută nodul **Pinecone Vector Store**.
- Imediat ce l-ai atașat pe planșă, dă click pe el pentru a-i deschide setările. La parametrul **Operation Mode**, asigură-te că este selectat **Retrieve Documents (As Tool for AI Agent)**. Asta îi spune nodului că rolul lui nu e să scrie date (ca în Cap. 5), ci să le citească.
- La câmpul **Description** (care are un triunghi roșu de avertizare), scrie clar o descriere pentru ca AI-ul să știe când să o apeleze: Folosește această unealtă pentru a căuta informații tehnice, log-uri sau planuri de testare în documentele echipei QA.
- Selectează credențialele tale Pinecone și, la câmpul **Pinecone Index**, alege baza noastră comună: n8n-qa-docs.

Schema Table JSON Parameters Settings Execute step

Tip: Get a feel for vector stores in n8n with our [RAG starter template](#)

Credential
Pinecone account

Operation Mode
Retrieve Documents (As Tool for AI Agent)

Description
Folosește această unealtă pentru a căuta informații tehnice, log-uri sau planuri de testare în documentele echipei QA.

Pinecone Index
From list n8n-qa-docs

Limit
4

☒ Include Metadata

☐ Rerank Results

Options +
+ Add Option


Output
1 item

4. Traducătorul Agentului (Embeddings)

Ca Agentul să caute în Pinecone, el trebuie să îți "traducă" întrebarea din limba română în aceleași numere (Vectori) pe care le-am folosit în Capitolul 5.

- Uită-te sub noul tău nod *Pinecone Vector Store* proaspăt atașat la Agent. Vei vedea că are și el un port inferior numit **Embeddings** (marcat cu o steluță roșie).
- Apasă pe el, caută în listă și alege **Embeddings OpenAI** (n8n le-a grupat recent punând cuvântul "Embeddings" la început).
- Selectează credențialele tale OpenAI și alege absolut același model pe care l-ai folosit

la ingestia de date: text-embedding-3-small.



Ochi de Arhitect (Cum funcționează RAG-ul?):


Arhitectura *Retrieval-Augmented Generation* pe care tocmai ai construit-o funcționează astfel:

- Tu întrebi: "Care sunt pașii de testare din document?"
- Agentul vede că nu știe din memorie, așa că apelează unealta *Pinecone*.
- Întrebarea ta este transformată în numere de nodul de Embeddings.
- Pinecone caută rapid în fragmentele salvate în Cap. 5 și returnează doar paragraful relevant.
- Agentul primește paragraful, îl citește fulgerător și îți formulează răspunsul perfect!


5. Momentul Adevărului: Conversația cu Datele Tale!

Acum e timpul să te bucuri de munca ta. Ai creat propriul tău asistent privat, bazat pe datele tale locale!

- În partea de jos a ecranului tău, vei vedea un buton numit **Open chat** (lângă butonul portocaliu de Execute). Apasă-l!



- Se va deschide o interfață similară cu ChatGPT, direct peste planșa ta.
- Scrie-i asistentului o întrebare specifică legată de conținutul fișierului de test pe care l-ai descărcat anterior. (Ex: *"Extrage te rog toate erorile găsite în log-ul meu"*).



Exercițiu de Gândire: "Personalitatea DevOps"

Deschide fereastra principală a nodului **AI Agent**. Vei vedea un câmp numit **System Message** (sau Prompt). Implicit este gol, iar asistentul tău este politicos, dar generic.

Cum ai formula un *System Message* pentru a-l transforma pe acest asistent într-un inginer DevOps morocănos, obosit de viață, care dă răspunsuri extrem de tehnice, dar corecte, folosind sarcasm? (Încearcă să scrii promptul tău direct în acel câmp și deschide Chat-ul din nou!).

